



## ارزیابی کارشناس هوش مصنوعی | مانا افراز خاور

### توضیحات پروژه:

هدف این تسک، ساخت یک سیستم پایه Retrieval-Augmented Generation (RAG) است که متون ورودی را به Embedding Vectors تبدیل کرده، در یک پایگاه داده برداری نگهداری می‌کند و هنگام دریافت پرسش کاربر، با جستجوی شباهت (Similarity Search) و تولید پاسخ توسط LLM، نتیجه نهایی را به همراه منابع ارائه می‌دهد.

### مواردی که لازم است انجام شود:

#### 1. انتخاب و توجیه پایگاه داده برداری

- استفاده از یک Vector DB.
- مستندسازی دلیل انتخاب بر اساس:
  - کارایی در جستجوی شباهت و درج داده،
  - مقیاس‌پذیری و شیوه استقرار،
  - پشتیبانی جامع کاربری و ابزارهای توسعه.

#### 2. مدل‌سازی داده

- طراحی اسکیمای ذخیره‌سازی شامل:
  - Document Text (متن بخش/چانک)،
  - Embedding Vector،
  - Metadata (شناسه سند، منبع، تاریخ، برچسب موضوعی و ...).
- توضیح چرایی این ساختار و اینکه چگونه به فیلترینگ بهتر، بهبود سرعت ارزیابی و ارتقای کیفیت RAG کمک می‌کند.

### 3. منطق سیستم RAG

#### ◦ *Ingestion Pipeline*

تقسیم متن به چانک‌های مناسب (طول/همپوشانی مشخص)،  
تولید Embedding با مدل سبک (مثلاً all-MiniLM-L6-v2)،  
ذخیره بردار + متادیتا در پایگاه داده برداری  
امکان قرار دادن PDF در یک پوشه مشخص

#### ◦ *Query Pipeline*

دریافت سؤال و تولید Embedding،  
بازیابی k چانک مشابه (با امکان فیلتر بر اساس متادیتا)،  
ساخت پرامپت حاوی دستورالعمل‌ها + زمینه بازیابی شده،  
ارسال به LLM و تولید پاسخ نهایی به همراه منابع.  
جداسازی کامل لایه RAG از LLM و استفاده از یک API رایگان یا کم‌هزینه (مثلاً JabirLLM یا Gemini Free) برای تولید پاسخ؛ به نحوی که LLM فقط بر پایه context بازیابی شده پاسخ بدهد و از خروج مستقیم محتوای دیتابیس بدون RAG جلوگیری شود.

### 4. پیاده‌سازی API با FastAPI (بخش اختیاری و امتیازی)

#### ◦ POST /ingest

ورودی: یک سند یا مجموعه‌ای از متون.  
عملیات: Chunking، تولید Embedding (مثلاً با sentence-transformers/all-MiniLM-L6-v2)  
یا هر مدل دلخواه) و ذخیره در Vector DB.  
خروجی: تأیید ثبت + خلاصه تعداد چانک‌ها/توکن‌ها/ابعاد بردار و شناسه‌ها.

#### ◦ POST /query

ورودی: پرسش کاربر (+ پارامترهای اختیاری مثل k، فیلتر متادیتا).  
عملیات: تبدیل پرسش به بردار، Similarity Search، انتخاب k نتیجه برتر، ساخت پرامپت ترکیبی و ارسال به LLM.

خروجی: پاسخ نهایی + فهرست context chunks (منابع، امتیاز شباهت).  
◦ مستندسازی خودکار API با Swagger/Redoc (FastAPI docs).

### 5. کیفیت و مستندات

- ثبت تنظیمات کلیدی (ابعاد بردار، k، آستانه شباهت، طول چانک/همپوشانی).
- توضیح طراحی پرامپت برای کاهش hallucination و وادار کردن مدل به استناد به منابع.
- راهنمای اجرا (README): نحوه راه‌اندازی، متغیرهای محیطی، نمونه درخواست/پاسخ.

## نکات کلیدی و موارد مهم

**1- زمان انجام تسک:** از زمانی که این تسک دریافت می‌شود، 72 ساعت فرصت دارید تا تسک را انجام داده و ارسال کنید.

**2- محیط اجرا:** پروژه را به صورت پابلیک در Github منتشر کنید.

- مخزن باید شامل موارد زیر باشد:

- کد کامل

- فایل requirements.txt یا environment.yml

- مستندات API (در صورت پیاده سازی)

- فایل README.md

**3- کیفیت کد و گزارش:**

- کد تمیز، خوانا، مستند و قابل اجرا باشد.

- نتایج و شیوه ارائه به شکل مرتب و شفاف بیان شود.

**4- مصاحبه فنی آنلاین:** در جلسه مصاحبه فنی، ممکن است درباره کد و نحوه پیاده سازی شما سؤال شود؛ آماده

توضیح منطق و روش کارتان باشید.

**5- ارتباط با ما:** در صورت داشتن هرگونه سؤال یا ابهام، می‌توانید از طریق همین ایمیل با ما در ارتباط باشید.

## توضیحات اضافی

- می‌توانید برای فیلترینگ متادیتا (مانند تاریخ/منبع/برچسب) در مرحله بازبایی، گزینه‌های اختیاری API قرار دهید.

- توجه به حریم خصوصی: اطمینان از عدم ارسال داده حساس به سرویس‌های بیرونی (در صورت نیاز به سانسور/ناشناس سازی).

- تمامی بخش‌های پیاده سازی شده با توابع درج شود.